

Repasso de SVD

Dada $A \in \mathbb{K}^{m \times n}$, existen matrices:

- $U \in \mathbb{K}^{m \times m}$ unitaria ($U^* = U^{-1}$)
- $\Sigma \in \mathbb{K}^{m \times n}$ diagonal
- $V \in \mathbb{K}^{n \times m}$ unitaria ($V^* = V^{-1}$)

Tales que $A = U \Sigma V^*$ y

$$\Sigma = \begin{pmatrix} \sigma_1 & & & & \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_m & \\ & & & & 0 \end{pmatrix} \text{ si } m \leq n$$

$$\overset{\circ}{\Sigma} = \begin{pmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & 0 \end{pmatrix} \text{ si } m > n$$

$\sigma_1 \geq \sigma_2 \geq \dots \geq 0$ son los valores singulares.

$$A = U \Sigma V^* \Leftrightarrow A \cdot V = U \cdot \Sigma$$

$n \times m$ $m \times m$

$$\text{Si } V = \begin{pmatrix} | & | & | \\ v_1 & v_2 & \dots & v_m \\ | & | & \dots & | \end{pmatrix}, \quad U = \begin{pmatrix} | & | & | \\ u_1 & u_2 & \dots & u_m \\ | & | & \dots & | \end{pmatrix}$$

$$\Rightarrow A \cdot V = \begin{pmatrix} | & | & | \\ Av_1 & Av_2 & \dots & Av_m \\ | & | & \dots & | \end{pmatrix}$$

Si $m \leq n$ $n - m$ zeros

$$U \cdot \Sigma = \begin{pmatrix} | & | & | & | & \dots & | \\ \sigma_1 u_1 & \sigma_2 u_2 & \dots & \sigma_m u_m & \dots & 0 \\ | & | & \dots & | & \dots & | \end{pmatrix}$$

y

$m > n$

$$U \cdot \Sigma = \begin{pmatrix} | & | \\ \sigma_1 u_1 & \sigma_n u_m \\ | & | \end{pmatrix}$$

En ambos casos $A \cdot V = U \cdot \Sigma$ da que

$$A \cdot v_i = \sigma_i \cdot v_i \quad i = 1, \dots, \min\{m, n\}$$

$$\text{Si } m \leq n \quad A \cdot v_i = \sigma_i \cdot v_i \quad i = 1 \dots m$$

$$A \cdot v_i = 0 \quad i = m+1, \dots, n$$

Si $m > n$ $A\mathbf{v}_i = \sigma_i \mathbf{v}_i \quad i=1 \dots n$
 $A\mathbf{v}_i$ libre $i=n+1, \dots, m$.

OBS: En ambos casos para los $\sigma_i = 0$
se tendrá $A\mathbf{v}_i = 0$.

Y en este caso vemos que $\sigma_i \cdot \mathbf{v}_i = 0$
también \Rightarrow esos \mathbf{v}_i son libres.

¿ Cómo construimos $\mathbf{U}, \bar{\Sigma}, \mathbf{V}$?

1) Planteamos $A^* A \in \mathbb{K}^{n \times n}$ que es hermitiana
 \Rightarrow existe una BON de autovectores
 $\mathbf{v}_1, \dots, \mathbf{v}_m$ y autovalores no negativos
 $\lambda_1 \geq \dots \geq \lambda_m \geq 0$ (los ordenamos)

$$\Rightarrow \mathbf{V} = \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_m \end{pmatrix}, \quad \sigma_i = \sqrt{\lambda_i}$$

$$\bar{\Sigma} = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_m & \\ & & & 0 \end{pmatrix} \quad ; \quad \bar{\Sigma} = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_m & \\ & & & 0 \end{pmatrix}$$

$$\sigma_i = \sqrt{\lambda_i}$$

$$2) \text{ Para } \sigma_i \neq 0 \quad u_i = \frac{1}{\sigma_i} A v_i \\ i=1, \dots, s$$

Para $\sigma_i = 0$ tenemos $A v_i = 0$

Para los $\sigma_{s+1}, \dots, \sigma_m$ que faltan completamos a una base

Valores singulares y norma 2

Vemos que:

$$\text{Teo: } A \in \mathbb{K}^{m \times n} \rightarrow \|A\|_2 = \sigma_1$$

Además, si $A \in \mathbb{R}^{m \times n}$ invertible

$$\rightarrow \|A^{-1}\|_2 = \frac{1}{\sigma_m} \quad \text{ya que}$$

val sing de A^{-1} son $1/\sigma_i, \sigma_i$ val

singular de A .

Ej: Probar $A \in \mathbb{K}^{n \times n}$ es invertible
si y solo si $\sigma_n > 0$.

heemos $\text{Cond}_2(A) = \sigma_1 / \sigma_n$.

Recordar que para matrices

simétricas $\text{Cond}_2(A) = \frac{\|\lambda_{\max}\|}{\|\lambda_{\min}\|}$

Si bien vimos que

$$\text{Cond}_2(A) \geq \frac{\|A\|}{\|A - B\|}$$

para B singular y que
entonces podría pensarse mal
condicionamiento de A con "una
cerca de A de una matriz
singular" vemos que

$\varepsilon \cdot \text{Id}$ está cerca de ser singular pero está super bien condic. $\text{Cond}_2(\varepsilon \text{Id}) = 1$


Para A invertible, podemos pensar que la condición sí tiene que ver con si hay mucha distancia entre los valores singulares de la matriz, es decir si

$$\sigma_1 \gg \sigma_n$$

$\Leftrightarrow \frac{\sigma_1}{\sigma_n}$ será grande.

Geométricamente, estamos mirando si los círculos tienden a estirar-

se muchos en un eje y compresión se muchos en otro.



Para matrices no cuadradas,
qué podemos decir?

Vimos la forma reducida:

Si $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > \sigma_{r+1} = 0$

$$\Rightarrow A = U_r \Sigma_r V_r^* \in \mathbb{K}^{m \times m}$$

donde $V_r = \begin{pmatrix} v_1 & \dots & v_r \\ \vdots & & \vdots \end{pmatrix} \in \mathbb{K}^{r \times m}$

$$\Sigma_r = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix} \in \mathbb{K}^{r \times r}$$

$$U_r = \begin{pmatrix} | & | \\ u_1 & \cdots & u_r \\ | & | \end{pmatrix} \in \mathbb{K}^{m \times r}$$

Por otros lados, si $k \leq r$

$$V_k = \begin{pmatrix} | & | \\ v_1 & \cdots & v_k \\ | & | \end{pmatrix} \quad \Sigma_k = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_k \end{pmatrix}$$

$$U_K = \begin{pmatrix} | & | \\ u_1 & \cdots & u_k \\ | & | \end{pmatrix}$$

$$A_k = V_k \Sigma_k U_k^*$$

$$= V_k (D_1 + \cdots + D_k) U_k^*$$

con $D_1 = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & 0 \end{pmatrix}, D_2 = \begin{pmatrix} 0 & \sigma_2 & 0 & \cdots & 0 \end{pmatrix}$

$$D_i = \begin{pmatrix} 0 & \sigma_i & 0 & \cdots & 0 \end{pmatrix} \rightarrow \text{lugar } i$$

$$= V_k D_i U_k^* + \dots + V_k D_k U_k^*$$

$$V_k D_i U_k^* =$$

$$\begin{pmatrix} & & \\ N_1 & \cdots & N_k \\ & & \end{pmatrix} \begin{pmatrix} 0 & & \\ & \ddots & \sigma_{i_0} \\ & & 0 \end{pmatrix} \begin{pmatrix} \bar{u}_1 \\ \vdots \\ \bar{u}_k \end{pmatrix}$$

$$= \begin{pmatrix} & & \\ N_1 & \cdots & N_k \\ & & \end{pmatrix} \begin{pmatrix} 0 & & & & 0 \\ 0 & \ddots & & & 0 \\ & \sigma_i \bar{u}_i & \ddots & & \\ 0 & & & \ddots & 0 \\ & & & & 0 \end{pmatrix}$$

$$= \begin{pmatrix} & & \\ \sigma_i N_i \bar{u}_i^1 & \cdots & \sigma_i N_i \bar{u}_i^k \\ & & \end{pmatrix}$$

$$= \sigma_i \begin{bmatrix} N_i \\ \bar{u}_i^* \end{bmatrix}$$

$$\Rightarrow A_k = \sigma_1 v_1 u_1^* + \dots + \sigma_k v_k u_k^*$$

que tiene rango k.

Teorema:

Vale que si $A \in \mathbb{K}^{m \times n}$ y

$\text{rg}(A) = r \Rightarrow \exists k \leq r$ se

tiene que A_k satisface

$$\|A - A_k\|_2 = \min \|A - B\|_2 = \sigma_{k+1}$$

$B \in \mathbb{K}^{m \times n} : \text{rg}(B) = k$

Es decir A_k es "la mejor"

aproximación en norma 2 de
matrices de la matriz A a
una matriz de rango k.

Aplicaciones

$$A = \begin{pmatrix} A \\ m \times m \end{pmatrix} = \begin{pmatrix} U \\ m \times m \end{pmatrix} \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_m \\ \hline & & 0 \end{pmatrix}_{m \times m} \begin{pmatrix} V^* \\ m \times m \end{pmatrix}$$

Si $\text{rg}(A) = r < m \Rightarrow \sigma_{r+1} = \dots = \sigma_m = 0$

$$\Rightarrow A = A_r = \begin{pmatrix} U_1 & \cdots & U_r \\ m \times r \end{pmatrix} \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix} \begin{pmatrix} V_1 & & \\ & \ddots & \\ & & V_r \end{pmatrix}_{r \times m}$$


OBS: $\underbrace{\begin{pmatrix} -v_1 & \cdots & -v_r \\ -v_r & \cdots & -v_1 \end{pmatrix}}_{r \times m} \underbrace{\begin{pmatrix} 1 & & \\ v_1 & \cdots & v_r \\ \vdots & & \vdots \end{pmatrix}}_{n \times m} = \mathbb{I}_r$

$$\Rightarrow A \cdot \begin{pmatrix} 1 & & \\ v_1 & \cdots & v_r \\ \vdots & & \vdots \end{pmatrix} = \begin{pmatrix} 1 & & \\ U_1 & \cdots & U_r \\ \vdots & & \vdots \end{pmatrix} \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix}$$

El resto $v_{r+1} \cdots v_m$ están en $N(A)$.

Aplicaciones:

- Reducción de dimensionalidad.
 m características (altura, peso, etc)



Puede haber
características
redundantes


$$\text{rg}(A) = r$$

si $k < r$

σ_{k+1} nos dice cuánta informa-
ción perdemos si usamos A_k
en lugar de $A = A_r$.

- Imágenes (en color, grises)

Grises 1000



pixels ~
 1000×2000

¿Cuántos tweets consumir?

$$A = U \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_{1000} & \\ & & & 0 \end{pmatrix} V^T$$

✓

- Algoritmos de recomendación

pelis 20.000 = n

usando svd

$$A = U \Sigma V^T$$

$m \times m$

$n \times n$

$m \times m$

$m \times m$

500.000 = m

$m \times m$


$m \times m$

Uso reducida: $r = \text{rg}(A)$

$$A = A_r = \begin{pmatrix} | & | \\ v_1 & \dots & v_r \\ | & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix} \begin{pmatrix} -v_1 & & \\ & \ddots & & \\ & & -v_r & \end{pmatrix}$$

$m \times r$

$r \times m$



"Las "características" son descond-
 cidas."

Cada

$$a_{ij} = q_i \cdot p_j$$

$\sqrt{\sum} q_i^2 = Q_r$
 $\sqrt{\sum} p_j^2 = P_r$
 Concentra el acción
 entre caract y
 características peli j.
 de usuario i

Se busca

a_{ij} de la q^t
queremos
 $\underbrace{}_2$

$$\min_{P, q} \sum_i \left(r_{i,j} - q_i^t p_j \right)$$
$$P, q \quad (i, j) \in \Omega + \delta \cdot \|Q_r\|_F^2 + \delta \cdot \|P_r\|_F^2$$
$$\downarrow$$
$$\Omega = \{(i, j) : r_{i,j} \text{ es conocido}\}$$

Conjunto de entrenamiento.

De Hatie (Tao 2009
Matzumura 2010)

$$\Omega = \{(i, j) : a_{ij} \text{ es conocido}\}$$

$P_\Omega(M) =$ dejar los m_{ij} con $(i, j) \in \Omega$
y cero en el resto

$P_{\Omega^c}(M) =$ dejar los m_{ij} con $(i, j) \notin \Omega$
y cero en el resto.

Aquí se muestran entradas originales

Se a M : minimizer

$$\frac{1}{2} \left\| \text{Pr}_2(A - M) \right\|_F + \lambda \left\| M \right\|_*$$

$\left(\sum \text{val} \sin^2 \right)^{1/2}$ $\sum \text{values}$

Los resuelven iterativamente; de M

1: M₀ usalquiera

$$A_1 = P_2(A) + P_{2+}(M_0)$$

$$2. \text{ Si } A_1 = \cup \Sigma^k$$

$$\Rightarrow M_1 = \cup S_\lambda(I) V^*$$

$$S_x(\vec{z}) = \text{diag}((d_{ii} - z)_+)$$

→ My matrix de Soto range

$\sigma \rightsquigarrow$ grande.

$$\| A_1 - M_1 \|_F = \| U (\bar{\Sigma} - S_\lambda(\bar{\Sigma})) V^* \|_F$$

$$= \| \bar{\Sigma} - S_\lambda(\bar{\Sigma}) \|_F$$

si λ est petit $\bar{\Sigma} \approx S_\lambda(\bar{\Sigma})$

si λ est grand $\bar{\Sigma} - S_\lambda(\bar{\Sigma}) \approx \bar{\Sigma}$