

Métodos iterativos

①

La resolución del sistema lineal $Ax = b$

Métodos directos

eliminación gaussiana

Métodos Iterativos

¿? clase de hoy

La aplicación de la iteración power

Método de la Potencia

$$v_{k+1} = \frac{A^k v_0}{\|A^k v_0\|_2} \quad \text{regla de normalización}$$

A cada iteración:

$$v_{k+1} = \frac{A v_k}{\|A v_k\|_2}$$

Escribiendo al vector v_k como combinación de la base de autovectores de A

$$v_k = A^k v_0 = a_1 (\lambda_1)^k w_1 + a_2 (\lambda_2)^k w_2 + \dots + a_m (\lambda_m)^k w_m$$

~~Método de Markov~~

Proceso de Markov

Estados de un sistema u_k y matriz de transiciones M

$$u_{k+1} = M u_k$$

M posee propiedades que definen al proceso de Markov

$$u_k = c_1 (\lambda_1)^k w_1 + c_2 (\lambda_2)^k w_2 + \dots + c_m (\lambda_m)^k w_m$$

Métodos Iterativos

2

Sistema lineal

$$Ax = b$$

Aproximación $x_k \rightarrow x$

$$\text{Residuo: } r_k = b - Ax_k$$

Precondicionador (Strong)

$$P \approx A$$

Proponemos:

$$Ax = b$$

$$Px + Ax = Px + b$$

$$Px = (P-A)x + b \quad (1)$$

Que pedimos a la matriz P ?

$$I \xrightarrow{P} A$$

- cercano a A
- de rápido cálculo (matrices esparsas)
- que acelere la convergencia del: nuevo x_{k+1} calculado a partir de x_k precedente.

$$Px_{k+1} = (P-A)x_k + b \quad (2)$$

Ahora:

$$(2) - (1)$$

$$P(x_{k+1} - x) = (P-A)(x_k - x)$$

$$P e_{k+1} = (P-A) e_k$$

$$\Rightarrow e_{k+1} = P^{-1}(P-A) e_k = (I - P^{-1}A) e_k$$

$$\Rightarrow e_{k+1} = M e_k$$

La velocidad de convergencia significa q' tan rápido $x_k \rightarrow x$ o sea que $e_k \rightarrow 0$.

La velocidad de convergencia depende enteramente de M (o sea $P^{-1}A$)

Convergencia

3

Llegamos a

$$e_{k+1} = M e_k$$

significa multiplicar por M todo e_k ; con lo que terminamos con una regla conocida fórmula

$$e_k = M^k e_0$$

Nos interesa saber si $e_k \rightarrow 0$, y qué tan rápido !!

Como puedo analizar la convergencia con las potencias de M ? \rightarrow los autovalores !!

Prescritimos ~~de~~ usando la base de autovectores de M y sus autovalores.

$$e_k = b_1 (\lambda_1)^k u_1 + b_2 (\lambda_2)^k u_2 + \dots + b_m (\lambda_m)^k u_m$$

y que precisamos?

$$\forall |\lambda(M)| < 1 \quad - \text{esto asegura convergencia}$$

Qué tan rápido converge?

Si todos $|\lambda| < 1$, el autovector más lento será aquel $|\lambda| \rightarrow 1$ o sea el máximo.

Recordamos q' llamamos RADIO ESPECTRAL $\rho(M)$, ~~$\rho(M) = \max |\lambda_i|$~~

$$= \max \{ |\lambda(M)| \} < 1$$

La componente b_1 , suponiendo $\rho(M) = \lambda_1$, depende de e_0 . Este factor decrece con λ_1^k .

(*) También podemos verlo usando ~~los~~ cualquier norma inducida $\|\cdot\|$.

$$\rightarrow \|e_k\| = \|M^k e_0\| \leq \|M^k\| \|e_0\| \leq \|M\|^k \|e_0\|$$

Si $\|M\| < 1 \rightarrow$ el error e_k tiende a 0, el método iterativo converge.

Costo del error

(4)

- $\|e_k\| \leq \|M\|^k \|e_0\| = \|M\|^k \|x_0 - x\|$
- $\|e_k\| \leq \frac{\|M\|^k}{1 - \|M\|} \|x_1 - x_0\|$ puedo acotar el error sin conocer x .

Condiciones para $\|M^k\| \rightarrow 0$
 $k \rightarrow \infty$

- M diagonalizable

$$M = C \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix} C^{-1}, \quad M^k = C \begin{pmatrix} \lambda_1^k & & 0 \\ & \ddots & \\ 0 & & \lambda_n^k \end{pmatrix} C^{-1}$$

$$\Rightarrow M^k \rightarrow 0 \Leftrightarrow \max_{1 \leq i \leq n} |\lambda_i| < 1 \Leftrightarrow \rho(M) < 1$$

- M hermitiano, $\rho(M) = \|M\|_2$

$$\Rightarrow M^k \rightarrow 0 \Leftrightarrow \|M\|_2 < 1$$

- Luego; en general decimos q:

Si: $M \in \mathbb{K}^{n \times n}$

$$\rho(M) < 1 \Leftrightarrow \lim_{k \rightarrow \infty} M^k = 0$$

Proposición:

$$\rho(M) = \inf_{\|\cdot\|} \|M\|$$

El infimo sobre todas las normas

significa que, $\forall \epsilon > 0$, $\exists \|\cdot\|$ tal que $\rho(M) \leq \|M\| \leq \rho(M) + \epsilon$ (3)

Demostración:

Dado $M \in \mathbb{K}^{n \times n}$

$$\|M\| = \sup_{x \in \mathbb{C}^n - \{0\}} \frac{\|Mx\|}{\|x\|}$$

Luego $\exists v \in \mathbb{C}^n$ autovector de M de autovalor λ , con $\rho(M) = |\lambda|$

$$\Rightarrow \|M\| = \sup_{x \in \mathbb{C}^n - \{0\}} \frac{\|Mx\|}{\|x\|} \geq \frac{\|Mv\|}{\|v\|} = |\lambda| = \rho(M)$$

$\Rightarrow \|M\| \geq \rho(M)$ que es lo que queríamos, c. lo (3)

Elección de P

- P = diagonal de A (Jacobi)
- P, triangular / ~~identidad~~ diagonal de A (Gauss-Seidel)

Ejemplo:

Jacobi

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}, \quad P = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

$$M = P^{-1}(P-A)$$

$$M = \begin{bmatrix} 0 & 1/2 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1/2 & 0 \end{bmatrix}$$

$$P x_{k+1} = (P-A) x_k + b$$

$$x_{k+1} = M x_k + P^{-1} b$$

$$\begin{bmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ x_3^{(k+1)} \end{bmatrix} = \begin{bmatrix} 0 & 1/2 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1/2 & 0 \end{bmatrix} \begin{bmatrix} x_1^k \\ x_2^k \\ x_3^k \end{bmatrix} + \frac{1}{2} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

$$\begin{bmatrix} x_1^{k+1} \\ x_2^{k+1} \\ x_3^{k+1} \end{bmatrix} = \begin{bmatrix} \frac{1}{2} x_2^k \\ \frac{x_1^k}{2} + \frac{x_3^k}{2} \\ \frac{x_2^k}{2} \end{bmatrix} + \begin{bmatrix} \frac{1}{2} b_1 \\ \frac{1}{2} b_2 \\ \frac{1}{2} b_3 \end{bmatrix}$$

En general

$$x_i^{(k+1)} = \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) / a_{ii}$$

PROUSS-SEIDEL

$$P^{-1} = \begin{bmatrix} 1/2 & 0 & 0 \\ 1/4 & 1/2 & 0 \\ 1/8 & 1/4 & 1/2 \end{bmatrix}$$

(6)

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

$$P = \begin{bmatrix} 2 & 0 & 0 \\ -1 & 2 & 0 \\ 0 & -1 & 2 \end{bmatrix}$$

$$M = \begin{bmatrix} 0 & 1/2 & 0 \\ 0 & 1/4 & 1/2 \\ 0 & 1/8 & 1/4 \end{bmatrix}$$

$$X_{k+1} = M_{GS} X_k + P^{-1} b$$

$$\begin{bmatrix} x_1^{k+1} \\ x_2^{k+1} \\ x_3^{k+1} \end{bmatrix} = \begin{bmatrix} 0 & 1/2 & 0 \\ 0 & 1/4 & 1/2 \\ 0 & 1/8 & 1/4 \end{bmatrix} \begin{bmatrix} x_1^k \\ x_2^k \\ x_3^k \end{bmatrix} + \begin{bmatrix} 1/2 & 0 & 0 \\ 1/4 & 1/2 & 0 \\ 1/8 & 1/4 & 1/2 \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

$$\begin{bmatrix} x_1^{k+1} \\ x_2^{k+1} \\ x_3^{k+1} \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{2} x_2^k & 0 \\ 0 & \frac{1}{4} x_2^k + \frac{1}{2} x_3^k & 0 \\ 0 & \frac{1}{8} x_2^k + \frac{1}{4} x_3^k \end{bmatrix} + \begin{bmatrix} \frac{1}{2} b_1 \\ \frac{1}{4} b_1 + \frac{1}{2} b_2 \\ \frac{1}{8} b_1 + \frac{1}{4} b_2 + \frac{1}{2} b_3 \end{bmatrix}$$

Vamos a reescribir

$$\begin{bmatrix} x_1^{k+1} \\ x_2^{k+1} \\ x_3^{k+1} \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{2} x_2^k & 0 \\ 0 & \frac{1}{2} \left(\frac{1}{2} x_2^k + \frac{1}{2} b_1 \right) + \frac{1}{2} x_3^k & 0 \\ 0 & \frac{1}{4} \left(\frac{1}{2} x_2^k + \frac{1}{2} b_1 \right) + \frac{1}{2} \left(\frac{1}{2} x_3^k + \frac{1}{2} b_2 \right) & 0 \end{bmatrix} + \begin{bmatrix} 1/2 b_1 \\ 1/2 b_2 \\ 1/8 b_1 + 1/4 b_2 + 1/2 b_3 \end{bmatrix}$$

$$\begin{bmatrix} x_1^{k+1} \\ x_2^{k+1} \\ x_3^{k+1} \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{2} x_2^k & 0 \\ 0 & \frac{1}{2} x_1^{k+1} + \frac{1}{2} x_3^k & 0 \\ 0 & \frac{1}{4} x_1^{k+1} + \frac{1}{4} x_3^k + \frac{1}{4} b_2 \end{bmatrix} + \begin{bmatrix} 1/2 b_1 \\ 1/2 b_2 \\ 1/2 b_3 \end{bmatrix}$$

$$= \begin{bmatrix} 0 & \frac{1}{2} x_2^k & 0 \\ 0 & \frac{1}{2} x_1^{k+1} + \frac{1}{2} x_3^k & 0 \\ 0 & \frac{1}{2} x_2^{k+1} & 0 \end{bmatrix} + \begin{bmatrix} 1/2 b_1 \\ 1/2 b_2 \\ 1/2 b_3 \end{bmatrix}$$

La fórmula general de Gauss-Seidel es

$$x_i^{k+1} = \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) / a_{ii}$$

Convergencia del ejemplo

⑦

$$\text{Autovectores de } M_J = \left(0, \frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right) \rightarrow \rho(M_J) = \left|\frac{1}{\sqrt{2}}\right| = 0,7071$$

$$\text{Autovectores de } M_{GS} = \left(0, 0, \frac{1}{2}\right) \rightarrow \rho(M_{GS}) = \left|\frac{1}{2}\right| = 0,5$$

La convergencia de M_{GS} es más rápida: $\rho(M_{GS}) < \rho(M_J)$

en general, para esta familia de matrices,

$$\lambda_{\max} @ \text{Jacobi} = \cos \frac{\pi}{n+1}$$

$$\lambda_{\max} @ \text{Gauss-Seidel} = \left(\cos \frac{\pi}{n+1}\right)^2 \rightarrow \lambda < 1 \rightarrow \text{Error al cuadrado} \rightarrow \text{Iter GS} = 2 \text{ iter J}$$

$\lambda @ \text{Jacobi}$

$$\lambda(A) = 2 - 2 \cos j\theta = 2 - 2 \cos j \frac{\pi}{n+1}$$

$$M = I - P^{-1}A = I - \frac{1}{2}A$$

$$\lambda_j(M) = 1 - \frac{1}{2} \lambda_j(A) = \cos j \frac{\pi}{n+1}$$

$$\lambda_{\max} = \cos \frac{\pi}{n+1} \rightarrow \lambda_{\max}(M) = \cos \theta \approx 1 - \frac{1}{2} \left(\frac{\pi}{n+1}\right)^2$$

$$\lambda_{\min} = \cos \frac{n\pi}{n+1} = -\lambda_{\max}$$

