

Métodos Iterativos

①

Repaso

- $Ax = b$
- $Px = (P-A)x + b$ usando un Precondicionador P

Iteración

$$Px_{k+1} = (P-A)x_k + b$$

Alternativas a los métodos directos y convenientes para matrices grandes, esparsas

$$e_{k+1} = x_{k+1} - x \quad , \quad e_k = x_k - x$$

$$Pe_{k+1} = (P-A)e_k$$

$$e_{k+1} = (I - P^{-1}A)e_k$$

$$\Rightarrow e_{k+1} = M e_k$$

- La convergencia está asegurada si $|\lambda(M)| < 1$
- La velocidad de convergencia la define el radio espectral

$$\rho(M) = \max \{ |\lambda(M)| \}$$

$$e_k = b_1(\lambda_1)^k u_1 + b_2(\lambda_2)^k u_2 + \dots + b_m(\lambda_m)^k u_m$$

Dos métodos de selección del Precondicionador:
si $A = D + L + U$

- Jacobi $\Rightarrow P = D$
- Gauss-Seidel $\Rightarrow P = D + L$
- $\rho(M_{GS}) = \rho(M_J)^2$


Ejemplo

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

$$\lambda_j(A) = 2 - 2 \cos j\theta, \quad \theta = \frac{\pi}{n+1} = \frac{\pi}{4}$$

$$|\lambda_j(M_J)| = \cos j\theta \quad \begin{cases} \lambda_1 = 1/2 \\ \lambda_2 = 0 \\ \lambda_3 = -\sqrt{2}/2 \end{cases}$$

$$|\lambda_j(M_{GS})| = (\cos j\theta)^2 \quad \begin{cases} \lambda_1 = 1/4 \\ \lambda_2 = 0 \\ \lambda_3 = 0 \end{cases}$$



Jacobi Ponderado

El preconditionador se elige sumando un factor w

$$P = wD, \quad w < 1$$

$$\Rightarrow M_w = I - wD^{-1}A$$

En nuestro ejemplo, $M = I - \frac{w}{2}A$

$$\text{Luego: } \lambda_j(M_w) = 1 - \frac{w}{2}(2 - 2\cos j\theta) = 1 - w + w\cos j\theta$$

$$\text{con } \theta = \frac{\pi}{m+1}$$

$$\lambda_j = \begin{cases} \lambda_1 = 0.8047 \\ \lambda_2 = 0.33 \\ \lambda_3 = -0.1381 \end{cases}$$

$$@ w = \frac{2}{3}$$

Successive Over-Relaxation (SOR) aka "sobre relajación sucesiva"

La idea parte de una simple adición de un factor w

$$\Rightarrow wAX = wb$$

$$\text{Si } P \quad Px_{k+1} = (P - wA)x_k + b$$

$$P = D + wL \rightarrow \text{Gauss-Seidel}$$

$$(D + wL)x_{k+1} = ((1-w)D - wU)x_k + wb$$

$$M_{\text{SOR}} = (D + wL)^{-1}((1-w)D - wU)$$

La idea es encontrar un w_{opt} que minimice el $\rho(M_{\text{SOR}})$

SOR (Continuación...)

(3)

Podemos también pensar al método como una magnificación de la dirección de x_k hacia x_{k+1} si es buena con $w > 1$:

$$x_{k+1} = x_k + w(x_{k+1} - x_k)$$

$$x_{k+1} = (1-w)x_k + w x_{k+1} \rightarrow \text{Prescribo Gauss-Seidel}$$

$$= (1-w)x_k + \frac{w}{a_{ii}} \left(b - \sum_{j=0}^{i-1} x_j^{(k+1)} a_{ij} - \sum_{j=i+1}^m a_{ij} x_j^{(k)} \right)$$

$$x_{k+1} \left(a_{ii} - w \sum_{j=0}^{i-1} a_{ij} \right) = \left[(1-w) a_{ii} - w \sum_{j=i+1}^m a_{ij} \right] x_k + w b$$

$$\star \underbrace{(D - wL)}_{(D - wL)} \quad \underbrace{((1-w)D - wU)}_{((1-w)D - wU)}$$

Tenemos 3 casos:

$w = 1 \rightarrow$ Gauss-Seidel

$w < 1 \rightarrow$ ~~menor~~ desaceleración

$w > 1 \rightarrow$ aceleración.

Por productos de matrices triangulares

$$\det(M_{SOR}) = (1-w)^m$$

Luego $\rho(M_{SOR}) \geq |1-w|$ recordando q' para la convergencia preciso

$$\rho(M_{SOR}) < 1$$

$$\Rightarrow |1-w| \rightarrow \boxed{0 < w < 2}$$

Para nuestro ejemplo:

$$M_{SOR} = (D + wL)^{-1} \left((1-w)D - wU \right)$$

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}$$

$$D = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix}$$


$$L = \begin{pmatrix} 0 & 0 & 0 \\ -1 & 0 & 0 \\ 0 & -1 & 0 \end{pmatrix} \quad U = \begin{pmatrix} 0 & -1 & 0 \\ 0 & 0 & -1 \\ 0 & 0 & 0 \end{pmatrix}$$

(4)

$$M_{SOR} = \begin{pmatrix} 2 & 2 & 0 \\ -w & 2 & 0 \\ 0 & -w & 2 \end{pmatrix} \begin{pmatrix} 2(1-w) + w & 0 \\ 0 & 2(1-w) + w \\ 0 & 0 & 2(1-w) \end{pmatrix}$$

$$M_{SOR} = \begin{pmatrix} 1-w & \frac{w}{2} & 0 \\ \frac{w(2w-2)}{4} & \frac{w^2}{4} - w + 1 & w/2 \\ \frac{w^2(2w-2)}{8} & \frac{w^3}{8} - \frac{w(2w-2)}{4} & \frac{w^2}{4} - w + 1 \end{pmatrix}$$

Probamos todos los w , y graficamos el radio espectral



Residuo

$$Px = (P-A)x + b$$

$$x_{k+1} = (I - P^{-1}A)x_k + b$$

$$x_{k+1} = x_k + P^{-1}(-Ax_k + b)$$

$$x_{k+1} = x_k + P^{-1}r_k$$

→ residuo

$r_k = Ax_k - b$ $r_k = b - Ax_k$

Método del Gradiente

Sea A simétrico definido positivo, $A \in \mathbb{R}^{n \times n}$, $x \in \mathbb{R}^n$

Dos problemas planteados

(P1) Hallar $x \in \mathbb{R}^n$ / $Ax = b$

(P2) Encontrar $x \in \mathbb{R}^n$ q' minimice la función cuadrática de energía:

$$J(x) = \frac{1}{2} x^T A x - x^T b$$

Se puede probar que ambos objetivos coinciden.
La idea es reemplazar la resolución del P1 x la metodología del tipo P2.

⇒ La minimización se define como:

$$\text{Encontrar } x \in \mathbb{R}^n \setminus J(x) = \min_{y \in \mathbb{R}^n} J(y)$$

Demostración: $t \in \mathbb{R}$, $z \in \mathbb{R}^n$, $x \in \mathbb{R}^n$

Sea
$$h(t) = J(x + tz) = \frac{1}{2} (x + tz)^T A (x + tz) - (x + tz)^T b$$

Luego

$$h(t) = \frac{1}{2} t^2 z^T A z + t (z^T A x - z^T b) + \frac{1}{2} x^T A x - x^T b$$

una cuadrática de variable t con mínimos:

$$t_{\min} = \frac{z^T A x - z^T b}{z^T A z} = \frac{z^T (Ax - b)}{z^T A z} = \frac{z^T (b - Ax)}{z^T A z}$$

Si x resuelve $P_1 \rightarrow Ax - b = 0$

(6)

$\rightarrow t_m = 0$

$\Rightarrow J(x) = h(0) \leq h(t) = J(x + tz), \forall t$ (1)

con $J(x) = \min_{y \in \mathbb{R}^m} J(y)$ que significa q resuelve P_2

De (1) vemos que su mínimo tiene que estar en $t=0$

$\Rightarrow 0 = \frac{z^T Ax - z^T b}{z^T Az} \Rightarrow z^T (Ax - b) = 0$

y si dijéramos $\forall z \neq 0$


$\Rightarrow Ax - b = 0$

$\Rightarrow x$ resuelve P_1

Descenso del Gradiente

Planteamos el problema $Ax = b$ como minimización de

$J(x) = \frac{1}{2} x^* A x - x^* b$



Atacamos la resolución de la minimización a partir de un método iterativo en \mathbb{R}^m .

Es un método por búsqueda de líneas, dado x_i se elige una dirección z_i y un escalar λ_i

$x_{i+1} = x_i + \lambda_i z_i$

\Rightarrow Empezamos buscando λ_i /

$J(x_i + \lambda_i z_i) = \min_{t \in \mathbb{R}} J(x_i + t z_i)$

que da

$\frac{dJ(x_i + tz_i)}{dt} \Big|_{t=\lambda_i} = \nabla J(x_i + \lambda_i z_i)^T z_i = 0$

Descenso del gradiente (Continuación ...)

(7)

Despejamos λ_i :

$$\lambda_i = \frac{-z_i^T (Ax_i - b)}{z_i^T A z_i} = \frac{z_i^T r_i}{z_i^T A z_i}$$

Bien! Tenemos λ_i ...

Pero nos falta fijar la dirección z_i : elegimos la dirección de mayor decrecimiento de J en x_i : $-\nabla J(x_i) = b - Ax_i = r_i$

\Rightarrow Esto define el método de descenso del gradiente & su opción más rápida: $x_{i+1} = x_i + \frac{r_i^T r_i}{r_i^T A r_i} r_i$

Pero !! puede ser muy lento



Gradiente Conjugado

Existe un modo de encontrar una dirección de búsqueda + adaptado.

Definimos, para una matriz simétrica definida positiva el producto interno de A :

$$x^T A x, \text{ con su norma } \|x\|_A = \sqrt{x^T A x}$$

Lema: Supongamos las direcciones de búsqueda son A ortogonales ($z_i^T A z_i = 0$), en cada paso se elige un λ_i para minimizar sobre la línea correspondiente:

$$\min_{x_i + \langle z_i \rangle} J(y) = J(x_{i+1}) = \min_{y \in x_0 + \langle z_0, z_1, \dots, z_i \rangle} J(y)$$

Demostación

Sea $W_{i+1} = \langle z_0, z_1, \dots, z_i \rangle$ y tomo $z \in x_0 + W_{i+1}$ arbitrario.

Juego puedo escribir: $z = y + t z_i$

con $y \in x_0 + W_i = x_0 + \langle z_0, z_1, \dots, z_{i-1} \rangle$

Observamos que

$$\min_{z \in x_0 + w_{i+1}} J(z) : \min_{y \in x_0 + w_i, t \in \mathbb{R}} J(y + tz_i)$$

Escribimos

$$J(z) = J(y + tz_i) = \frac{1}{2} t^2 z_i^T A z_i + t (z_i^T A y - z_i^T b) + \frac{1}{2} y^T A y - y^T b \quad (1)$$

Pero sabemos q' son A ortogonales: $z_i^T A z_j = 0$

$$J(y + tz_i) = \left(\frac{1}{2} t^2 z_i^T A z_i + t (z_i^T A x_0 - z_i^T b) \right) + \frac{1}{2} y^T A y - y^T b$$

gracias a este desdoblamiento y de los términos

Pero minimizar en z basta minimizar ambos términos:

- 1º en t
- 2º en y (método de descenso de líneas)

Pero el λ óptimo es $\lambda = \frac{z_i^T A z_i}{z_i^T A z_i}$ por los resultados ya encontrados

Lo interesante es que lo minimizamos del $J(z)$,

Para $\min J(z)$ preciso $J(y)$

$$z \in x_0 + w_{i+1} \quad y \in x_0 + w_i$$

para minimizar el espacio w_{i+1} preciso minimizar en w_i

que es menor.

Aquí sale la recursión \rightarrow es lo que el algoritmo

Método

Buscamos generar una base ortogonal sin hacer Gram-Schmidt. La base de residuos es ortogonal:

$$r_i^T r_k = 0, \quad k < i$$

Δr es ortogonal a previos Δx

$$(x_i - x_{i+1})^T (r_k - r_{k-1}) = 0 \quad i < k$$

Δy y Δr directamente relacionados

$$r_k - r_{k+1} = (b - Ax_k) - (b - Ax_{k+1}) = -A(x_k - x_{k+1})$$

Método (Continuación...)

9

$$\text{Juego } (x_i - x_{i+1})^T A (x_k - x_{k-1}) = 0 \quad i < k$$

Los updates Δx son A ortogonales o "conjugados"

Escribimos la dirección de búsqueda en esa base de residuos (ortogonales) como su combinación lineal

$$z_i = \sum_{j=0}^i \frac{z_i^T r_j}{r_j^T r_j} r_j$$

Ya sabemos

$$\textcircled{1} - z_i^T r_i = r_i^T r_i \quad (\text{demostración en apunte})$$

$$\textcircled{2} - z_i^T (r_i - r_i) = z_i^T A (x_i - x_i) = 0 \quad \left| \begin{array}{l} x_i - x_i \in W_i \\ \text{y } z_i \perp A \text{ ortogonal a } W_i \end{array} \right.$$

$$z_i = \sum_{j=0}^i \frac{z_i^T r_j}{r_j^T r_j} r_j \stackrel{\text{por } \textcircled{1} \text{ y } \textcircled{2}}{=} \sum_{j=0}^i \frac{r_i^T r_j}{r_j^T r_j} r_j = r_i + r_i^T r_i \sum_{j=0}^{i-1} \frac{r_j}{r_j^T r_j}$$

Multiplico y divido $\times \frac{r_{i-1}^T r_{i-1}}{r_{i-1}^T r_{i-1}}$

$$z_i = r_i + \frac{r_i^T r_i}{r_{i-1}^T r_{i-1}} \sum_{j=0}^{i-1} \frac{r_{i-1}^T r_{i-1}}{r_j^T r_j} r_j = r_i + \frac{r_i^T r_i}{r_{i-1}^T r_{i-1}} z_{i-1}$$

Llegamos a la forma recursiva.

Tenemos todos los elementos para definir el método del Gradiente Conjugado.

Por $i=0$, $x_0 = r_0$, $z_0 = r_0 = b$ (subespacios de k y l)

$$\textcircled{1} \lambda_{i+1} = \frac{r_i^T r_i}{z_i^T A z_i}$$

$$\textcircled{2} x_{i+1} = x_i + \lambda_{i+1} z_i$$

$$\textcircled{3} r_{i+1} = r_i - \lambda_i A z_i$$

$$\textcircled{4} z_{i+1} = r_{i+1} + \frac{r_{i+1}^T r_{i+1}}{r_i^T r_i} z_i$$

fin



Cota del error

$$\|x - x_k\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|x - x_0\|_A$$

La raíz de la condición de A favorece la convergencia.

Ejemplo

$$Ax = b \quad A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix} \quad \begin{bmatrix} 3 \\ -1 \\ -1 \end{bmatrix} = \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix}$$

$$x_0 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \quad r_0 = z_0 = b = \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix}$$

$$\lambda_1 = \frac{r_0^T r_0}{z_0^T z_0} = \frac{1}{2}$$

$$x_1 = x_0 + \lambda_1 \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix}$$

$$r_1 = r_0 - \frac{1}{2} A z_0 = \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix} - \frac{1}{2} A \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ -2 \\ -2 \end{bmatrix}$$

$$z_1 = r_1 + \frac{r_1^T r_1}{r_0^T r_0} z_0 = \begin{bmatrix} 2 \\ -2 \\ -2 \end{bmatrix}$$

$$\lambda_2 = \frac{r_1^T r_1}{z_1^T A z_1} = \frac{1}{2}$$

$$x_2 = x_1 + \frac{1}{2} z_1 = \begin{bmatrix} 3 \\ -1 \\ -1 \end{bmatrix}$$

$$r_2 = r_1 - \frac{1}{2} A z_1 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \quad \text{stop}$$